
Big data en el cloud público

PID_00284064

Guillermo Argüello Gonzalez

Tiempo mínimo de dedicación recomendado: 2 horas



Guillermo Argüello Gonzalez

El encargo y la creación de este recurso de aprendizaje UOC han sido coordinados por el profesor: Albert Solé Ribalta

Primera edición: septiembre 2021
© de esta edición, Fundació Universitat Oberta de Catalunya (FUOC)
Av. Tibidabo, 39-43, 08035 Barcelona
Autoría: Guillermo Argüello Gonzalez
Producción: FUOC
Todos los derechos reservados

Ninguna parte de esta publicación, incluido el diseño general y la cubierta, puede ser copiada, reproducida, almacenada o transmitida de ninguna forma, ni por ningún medio, sea este eléctrico, mecánico, óptico, grabación, fotocopia, o cualquier otro, sin la previa autorización escrita del titular de los derechos.

Índice

Introducción.....	5
1. Características de las plataformas en la nube.....	7
1.1. Introducción	7
1.2. Características de las nubes de computación públicas	8
1.3. Capas en la nube	9
1.3.1. IaaS (<i>Infrastructure as a Service</i>)	10
1.3.2. PaaS (<i>Platform as a Service</i>)	11
1.3.3. SaaS (<i>Software as a Service</i>)	11
1.4. Riesgos de los entornos <i>cloud</i>	12
2. AWS.....	15
2.1. Almacenamiento	16
2.2. Ingesta (captura de datos)	16
2.3. Procesamiento	17
2.4. Búsqueda y visualización	18
3. Azure y Google Cloud.....	22
3.1. Azure	22
3.2. Google Cloud	24
Bibliografía.....	27

Introducción

La última gran revolución en el mundo del *big data* y de la computación distribuida ha sido la aparición de las plataformas *cloud* públicas o nubes de computación, definidas como un conjunto de ordenadores conectados entre sí y accesibles mediante Internet que se encargan de prestar un servicio de computación *big data* contratable por cualquier usuario que desee usarlo.

En los módulos anteriores habéis visto tecnologías *big data* que se enmarcan, principalmente, en el ecosistema Hadoop, que es probablemente el *stack* tecnológico predominante para el procesamiento y almacenamiento distribuido. En los inicios, cuando apareció Hadoop era habitual instalarlo en clústeres *on-premise*, es decir, en un conjunto de máquinas que cada empresa o institución compraba y mantenía. Las máquinas que formaban parte de los clústeres *on-premise* eran propiedad de la entidad y estaban físicamente ubicadas en los CPD (centro de proceso de datos o *data center*) de estas. Esto permitía tener un control total de la infraestructura y de la gestión de los datos, ya que estos estaban almacenados físicamente en sus servidores. Sin embargo, la creación de un clúster *on-premise* requiere una gran inversión inicial para adquirir todas las máquinas necesarias (hardware), un gran equipo técnico para administrarlo y, seguramente, comprar e instalar nuevas máquinas cuando el clúster inicial se quede pequeño. Todo esto hacía que las empresas pequeñas y medianas difícilmente pudiesen acceder a los servicios *big data*.

Para solventar estos problemas varias empresas tecnológicas dedicadas a los servicios en línea vieron un nicho de mercado, ofrecer al usuario una tecnología *big data* en línea, configurable, de bajo mantenimiento y sin prácticamente inversión inicial. En 2002, Amazon anuncia el lanzamiento de su infraestructura *big data* en la red con el lanzamiento de Amazon Web Service que posteriormente, en 2006, amplió. En 2009 Google y otros grandes proveedores, siguiendo la estela, empezaron también a ofrecer aplicaciones similares accesibles en línea mediante WebUI (navegadores web), elemento que las popularizó y les hizo ganar seguridad y servicio. También otros grandes proveedores implementan sus propias infraestructuras *cloud*, por ejemplo: Microsoft Azure, que fue anunciado en octubre de 2008 (pero no es hasta 2010 que comienza a prestar servicios); IBM en 2011 (lanza SmartCloud Framework para dar soporte a su proyecto Smarter Planet); u Oracle en 2012 (Oracle Cloud). Con la aparición de las plataformas en la nube las empresas ya no necesitan tener la infraestructura en propiedad, sino que la pueden alquilar bajo demanda, pagando exclusivamente por el uso que se hace de ella.

Una definición interesante que aporta un buen punto de partida sobre el *cloud computing* es la que realiza el National Institute of Standards & Technology (NIST), que expresa lo siguiente:

«El cloud computing es un modelo que permite acceso ubicuo, a conveniencia, bajo demanda y por red a un conjunto compartido de recursos informáticos configurables (por ejemplo, redes, servidores, almacenamiento, aplicaciones y servicios) que pueden ser rápidamente aprovisionados y liberados con el mínimo esfuerzo de administración o sin interacción del proveedor de servicios» (Mell y Grance, 2011).

La aparición de los grandes proveedores de *cloud* ha cambiado la forma de trabajar en el mundo del *big data*, simplificando en gran medida la gestión de la infraestructura, que era uno de los aspectos más complicados. Por medio de una *user interface* (UI) se puede acceder a la plataforma de gestión de todos los servicios del *cloud* sin tener que instalar ningún software en vuestro escritorio y haciendo sencillo trabajar desde cualquier lugar y a cualquier hora.

A lo largo de este módulo se analizarán las diferentes capas de las que disponen las nubes y se comentarán sus características. Finalmente se centrará en describir cómo operan los tres grandes proveedores de *cloud* de la actualidad: Google Cloud, Azure y AWS.

1. Características de las plataformas en la nube

1.1. Introducción


En este apartado vais a ver las características más importantes de las plataformas en la nube y las diferentes capas que tienen. El concepto de *nube* es amplio y engloba diferentes modelos que se pueden resumir en varias tipologías en función de las necesidades de negocio de los usuarios, las empresas o instituciones que lo usan:

- **Nube privada.** Lo que se conoce como nube privada es el caso clásico en el que la empresa compra, mantiene y gestiona una serie de máquinas que forman un clúster de computación y almacenamiento. En una nube privada las máquinas que la conforman son usadas solo por la empresa a la que pertenecen. Es lo que se conoce también como infraestructura *on-premise*. Como ejemplo se pueden considerar los ejercicios prácticos introducidos a lo largo de los módulos, estos se han desarrollado en una nube privada propiedad de la UOC en la que se ha instalado una distribución de Cloudera. Este tipo de nube es útil para empresas que tienen información altamente confidencial o se hace un uso muy intensivo de los recursos, pero su mantenimiento e instalación es costosa.
- **Nube pública.** En este tipo de nubes toda la infraestructura es mantenida por la empresa proveedora del servicio que generalmente será Google (por medio de Google Cloud), Microsoft (con Azure) o Amazon (con AWS). En este tipo de nubes tanto los datos de los clientes como los procesos utilizan los servidores, sistemas de almacenamiento y otras infraestructuras de la nube. Los usuarios no se tienen que preocupar del mantenimiento de la infraestructura ni de la instalación de los servicios. Este tipo de nubes son el objeto de estudio de este módulo.
- **Nube híbrida.** Esta opción combina los dos tipos de nubes citadas anteriormente. Cuando las empresas implementan nubes híbridas tienen parte del procesamiento en sus máquinas propias y parte del procesamiento se hace en una nube pública, permitiendo así el escalado en procesos muy pesados. Tiene la ventaja de poder ejecutar aplicaciones en la nube privada asegurando también una mejor protección de datos, sumándole las ventajas de la nube pública en cuanto a escalabilidad.
- **Cloud comunitario.** *Cloud* que yace en medio de la nube privada y pública. Los servicios están diseñados para que puedan ser utilizados por una comunidad, organizaciones o empresas bajo el mismo alineamiento de objetivos o negocio (por ejemplo, bancos, distribuidores, arquitectos, etc.)

o que requieran unas características específicas (por ejemplo, seguridad y privacidad). Las empresas que forman la comunidad pueden ser los propietarios de la infraestructura, así como los gestores u operadores; algunos de estos roles pueden ser subcontratados a terceros, pero bajo las indicaciones y reglas que aplica a la comunidad.

La figura 1 muestra un esquema de estas cuatro formas de implantación y desarrollo de los *clouds*.

Figura 1. Los diferentes tipos de arquitecturas *cloud*



Fuente: Suppi Boldrito (2017).

1.2. Características de las nubes de computación públicas

La computación en la nube presenta las siguientes características fundamentales:

- **Agilidad.** Capacidad de mejora para ofrecer recursos tecnológicos al usuario por parte del proveedor.
- **Coste.** El coste del uso del *cloud* corresponde solo al uso de infraestructura y servicios que se consumen, eliminando los costes iniciales de la compra de las máquinas y de su mantenimiento. También reduce la barrera de entrada, empresas más pequeñas sin muchos recursos económicos pueden acceder a los servicios *cloud* públicos mientras que les sería imposible montar la infraestructura *on-premise*. Por otro lado, hay que ser cuidadosos y utilizar solo lo que se necesita porque si no los costes pueden ser más

elevados que en las arquitecturas *on-premise*. Cuanto más intensivo sea el uso que se hace de los servicios *cloud* peor va a ser su balance económico en comparación con las implementaciones *on-premise*.

- **Escalabilidad y elasticidad.** Aprovisionamiento de recursos sobre una base de autoservicio casi en tiempo real. En todos los proveedores podéis crear clústeres bajo demanda en pocos minutos con muchos tipos diferentes de máquinas según vuestras necesidades o aumentar el número de máquinas de un clúster ya existente si así lo necesitáis.
- **Independencia entre el dispositivo y la ubicación.** Permite a los usuarios acceder a las plataformas utilizando un navegador web, independientemente de su ubicación o del dispositivo que utilice (por ejemplo, PC o teléfono móvil), facilitando el trabajo desde diferentes lugares y horarios.
- **Tecnología de virtualización.** Permite compartir servidores y dispositivos de almacenamiento y una mayor utilización. Las aplicaciones pueden ser fácilmente migradas de un servidor físico a otro.
- **Rendimiento.** Los sistemas en la nube controlan y optimizan el uso de los recursos de manera automática, dicha característica permite un seguimiento, control y notificación de este. Esta capacidad aporta transparencia tanto para el consumidor como para el proveedor de servicio.
- **Seguridad.** Puede mejorar debido a la centralización de los datos, aunque cuando se suben los datos al *cloud* desde los servidores de una organización estos están expuestos a Internet y pueden sufrir ataques. Además, se pierde el control físico de los datos ya que estarán almacenados en servidores del proveedor de *cloud* que se contrate.
- **Mantenimiento.** En el caso de las aplicaciones de computación en la nube el mantenimiento es más sencillo, ya que no necesitan ser instaladas en el ordenador de cada usuario y se puede acceder desde diferentes lugares. Además, el proveedor se encarga del mantenimiento de la infraestructura, que suele ser uno de los mayores puntos de fallo.

1.3. Capas en la nube

Habitualmente se clasifican los *clouds* en función del servicio que prestan y normalmente están categorizados en los tres modelos principales que se detallarán a continuación: infraestructura como servicio (*Infrastructure as a Service* - **IaaS**), plataforma como servicio (*Platform as a Service* - **PaaS**) y software como servicio (*Software as a Service* - **SaaS**). Aunque hoy podéis encontrar otras

extensiones o derivadas de los habituales como pueden ser BaaS (*Business as a Service*), SaaS (*Storage as a Service*), DaaS (*Desktop as a Service*), DRaaS (*Disaster Recovery as a Service*) MaaS (*Marketing as a Service*), etc.

En general todos los proveedores ofrecen los tres modelos básicos, IaaS, PaaS y SaaS, a los usuarios que podrán elegir uno u otro en función de sus necesidades. La diferencia, como veréis a continuación, está en la abstracción que se obtiene como usuarios. Hay que tener en cuenta que la plataforma como servicio y el software como servicio funcionan sobre IaaS, ya que en ambas el usuario se desentiende del uso de la infraestructura. La diferencia fundamental entre estos tres tipos de plataformas viene dada por el tipo de servicio, mantenimiento y soporte que ofrezca el proveedor. Por ejemplo, en una plataforma IaaS el usuario tiene acceso al hardware y software instalado y su configuración, mientras que los usuarios de un servicio SaaS no tienen. En cambio, en un servicio PaaS solo se tiene acceso al software que forme parte de la plataforma contratada.

1.3.1. IaaS (*Infrastructure as a Service*)

Es un modelo en el cual la infraestructura básica de cómputo (servidores, software y equipamiento de red) es gestionada por el proveedor como un servicio bajo demanda, en el cual se pueden crear entornos para desarrollar, ejecutar o probar aplicaciones. En este modelo el proveedor de *cloud* se encarga de mantener y aprovisionar las máquinas que va a utilizar el cliente y el cliente gestiona todo lo demás: el software que hay que instalar, el desarrollo de las aplicaciones, etc. El fin principal de este modelo es evitar la compra de recursos por parte de los suscriptores, ya que el proveedor ofrece estos recursos como objetos virtuales accesibles por medio de una interfaz de servicio. El suscriptor mantiene generalmente la capacidad de decisión del sistema operativo y del software que instala. Por lo tanto, la gestión de la seguridad corre principalmente a cargo del suscriptor.

El modelo de negocio básico de este tipo de servicio es que el cliente contrata al proveedor las máquinas que necesita bajo demanda y durante el tiempo que las necesita, pagando solo por ese tiempo de uso, y una vez que no las necesita las libera y el proveedor deja de cobrar por el servicio. El ejemplo de IaaS más extendido hoy, y quizá el primero en popularizarse, es el servicio de AWS EC2, que permite a los usuarios alquilar servidores virtuales en los cuales pueden instalar sus aplicaciones. AWS ofrece al usuario una gran variedad de máquinas diferentes, con diferente CPU, RAM y capacidad de almacenamiento, el usuario elige la máquina que más conviene a sus necesidades y paga en función del tiempo que la utilice y del tamaño de esta.

1.3.2. PaaS (*Platform as a Service*)

En el modelo de plataforma como servicio o PaaS (del inglés, *Platform as a Service*) el servicio se entrega bajo demanda, desplegándose el entorno (hardware y software) necesario para ello. De esta forma se reducen los costes y la complejidad de la compra, mantenimiento, almacenamiento y control del hardware/software que componen la plataforma. El suscriptor del servicio tiene control parcial sobre las aplicaciones y la configuración del entorno, ya que la instalación en estos dependerá de la infraestructura que el proveedor del servicio haya desplegado. La seguridad se comparte entre el proveedor del servicio y el suscriptor.


El cliente no gestiona ni controla la infraestructura (ni servidores, ni sistemas operativos, ni almacenamiento, ni ningún tipo de elementos de red o seguridad, etc.), pero tiene el control de las aplicaciones desplegadas y de la configuración del entorno de ejecución de estas (bases de datos y *middlewares*). Es habitual que una PaaS pueda prestar servicios en todos los aspectos del ciclo de desarrollo y pruebas de software o en un desarrollo, gestión y publicación de contenidos. Un ejemplo es **Google App Engine**, este servicio de Google da al usuario la capacidad de publicar aplicaciones web en línea, sin tener que gestionar la infraestructura donde hacerlo. En este caso el usuario se enfoca solamente en la construcción y la configuración de sus aplicaciones, y es Google la encargada de aprovisionar de los recursos necesarios.

1.3.3. SaaS (*Software as a Service*)

Este modelo, software como servicio o SaaS (del inglés, *Software as a Service*), consiste en un despliegue de software en el cual las aplicaciones y los recursos computacionales se han diseñado para ser ofrecidos como servicios de funcionamiento bajo demanda, con estructura de servicios llave en mano. De esta forma se reducen los costes tanto de software como de hardware, así como los gastos de mantenimiento y operación. Las consideraciones de seguridad son controladas por el proveedor del servicio. El suscriptor del servicio únicamente tiene acceso a la edición de las preferencias y a unos privilegios administrativos limitados.

Este modelo de servicio se puede resumir diciendo que el proveedor del servicio ofrece un servicio integral al usuario. El usuario usa el servicio contratado que ya está configurado y es completamente funcional por parte del proveedor. En vuestro día a día utilizáis servicios de este tipo, un ejemplo es Gmail, el correo de Google, que utilizáis como usuarios finales sin encargaros de ningún aspecto de su gestión. Otro ejemplo es **Microsoft Office 365**, con esta plataforma de Microsoft los usuarios pueden acceder al paquete de Office de Microsoft desde cualquier dispositivo, ejecutándose los servicios en servidores de Microsoft. El usuario solo se ocupa de utilizar la aplicación sin tener que preocuparse por su instalación, mantenimiento y actualización.

Figura 2. Principales características de la IaaS, PaaS y SaaS



Fuente: Comparativa Clouds. <<https://comparacloud.com/servicios-clouds/iaas-paas-saas/>>.

1.4. Riesgos de los entornos *cloud*


Los *clouds* públicos son una de las grandes revoluciones de los últimos años en el procesamiento y el almacenamiento de grandes volúmenes de datos, pero tienen ciertos riesgos asociados a su naturaleza:

- Seguridad y privacidad.** Este punto supone la mayor preocupación para muchas empresas respecto al *cloud computing*, ya que tanto las máquinas que se utilizan como la gestión del almacenamiento de los datos son responsabilidad de la empresa proveedora de los servicios *cloud*. Entregar la información sensible a una tercera empresa y dejar de tener almacenados estos datos en un servidor *on-premise* propio de la empresa siempre supone un riesgo y una preocupación. En cualquier caso, los proveedores de *cloud* público hacen grandes esfuerzos para asegurar la seguridad de todos los datos almacenados en sus servidores y tienen implementados varios mecanismos de seguridad y de protección en las cuentas de los usuarios. Es interesante conocer que algunos proveedores intentan reducir la probable inseguridad por medio de servicios de conexión directa (por ejemplo, AWS Direct Connect o Azure ExpressRoute), que permiten que los clientes puedan comprar o alquilar una conexión privada para conectarla a un punto privado del proveedor, con el consiguiente incremento de la privacidad que significa un recurso de este tipo.

- **Localización de los datos.** Las empresas de *cloud* público tienen sus datos deslocalizados alrededor de distintos países. Se debe consultar con los proveedores cuál es el marco regulatorio aplicable al almacenamiento y procesamiento de datos, siendo una buena práctica cerrar un acuerdo con el proveedor para que el tratamiento de los datos se subyugue al marco legal del país del suscriptor del servicio. Por ejemplo, la UOC no permite tener los datos fuera de la Unión Europea, por lo tanto, cuando utiliza AWS tiene que elegir como región geográfica para las máquinas alguna de las que están dentro de la Unión Europea.
- **Vendor lock-in.** Este concepto se puede traducir como ‘dependencia del proveedor’. Una vez que se elige un proveedor de *cloud* y se empiezan a desarrollar aplicaciones en sus sistemas es muy difícil migrar a otro proveedor si se desea, porque se generan muchas dependencias de servicios propios y exclusivos del proveedor.
- **Gobierno de acceso e identidades.** En todos los *clouds* públicos el acceso de los usuarios es con una web (UI). Una de las causas más frecuentes de las brechas de seguridad es la deficiencia en las medidas de control y gobierno de los accesos y la identidad de los usuarios.

En la figura 3 se muestran, en forma resumida, tanto las características a favor del *cloud computing* como aquellas que no son tan favorables y que pueden representar un riesgo y que se deberán analizar con cuidado.

Figura 3. Cuadro resumen de ventajas e inconvenientes de los servicios *cloud*



Fuente: Suppi Boldrito (2017).

En la figura 3 se destacan como ventajas del *cloud* el escalado, aprovisionamiento y disponibilidad inmediata, seguridad, orientación a servicio, reducción de consumo de energía, centralización de recursos y no tener que disponer de personal especializado en infraestructura en la empresa. Como desventajas se indican el coste de una posible migración (*vendor lock-in*), cuestiones legales por la ubicación física de los datos, seguridad, disponibilidad y fiabilidad (dependiendo de las tarifas que pague el cliente, el proveedor no garantiza

la disponibilidad), SLA (*Service Level Agreement*), que es un acuerdo escrito entre un proveedor de servicio y su cliente con objeto de fijar el nivel acordado para la calidad de dicho servicio.


2. AWS

En 2006, Amazon Web Services (AWS)⁽¹⁾ comenzó a proporcionar servicios de infraestructura de TI para empresas en forma de servicios web. Hoy en día, Amazon Web Services proporciona una plataforma de infraestructura escalable, de confianza y de bajo costo en la nube que impulsa cientos de miles de negocios de 190 países de todo el mundo. AWS es el proveedor web con más cuota de mercado, un 32 % en 2020 y con centros de datos en Estados Unidos, Europa, Brasil, Singapur, Japón y Australia, y clientes de todos los sectores.

(1)<https://aws.amazon.com/es/>

AWS dispone hoy en día de más de doscientos servicios. En este apartado veréis los servicios más importantes de captura, almacenamiento, procesamiento y visualización de datos. De esta forma se introducirá un subconjunto de las herramientas que os permitirían ejecutar un proyecto entero en AWS similar a los que podríais desarrollar en un entorno *big data on-premise*, por ejemplo, dentro de una instalación Cloudera. En la figura 4 podéis encontrar un mapa de las herramientas más importantes y utilizadas en AWS para ejecutar un proyecto *big data* y para construir un *data lake*, esta arquitectura está desarrollada en detalle en el documento de la referencia (Amazon Web Services, 2020).

Figura 4. Potencial conjunto de tecnologías usadas en un proyecto *big data* en AWS



Fuente: AWS. <<https://docs.aws.amazon.com/wellarchitected/latest/analytics-lens/wellarchitected-analytics-lens.pdf#document-revisions>>.

En la figura 4 se pueden ver algunos de los servicios más importantes de AWS, los más utilizados se detallarán en los siguientes apartados. Podéis observar que todos los servicios giran en torno al repositorio central y común de datos que es S3 (elemento 1 en la figura). Esto es habitual en todas las tecnologías *big data*, tal y como visteis con Hadoop/Spark y HDFS. Igual que visteis en los entornos *on-premise* durante el curso, los servicios se clasifican según su funcionalidad. AWS dispone de herramientas de *data ingestion* (2 en la figura) como Kinesis o Snowball, herramientas de procesamiento y análisis (3 en la figura) como EMR o Athena, servicios de seguridad y gobierno (4 en la figura) como IAM o KMS, catálogos y servicios de búsqueda (5 en la figura) como Glue o DynamoDB y herramientas de gestión de accesos para usuarios (6 en la figura) como Cognito o AppSync.

Bibliografía complementaria

Para ampliar el contenido de AWS del presente documento podéis consultar la web oficial de AWS con todos los manuales técnicos.

2.1. Almacenamiento

En primer lugar, se va a hablar de Amazon Simple Storage Service (Amazon S3), que es el repositorio central de almacenamiento de datos en AWS. S3 es la parte central de AWS, ya que es el repositorio de datos que todas las demás herramientas de AWS soportan. S3 soporta el almacenamiento de cualquier tipo de fichero y es prácticamente el equivalente en funcionalidad al Hadoop Distributed File System (HDFS). A continuación, vais a ver los conceptos clave en los que se basa S3:

- **Objetos.** Los objetos son las entidades fundamentales almacenadas en Amazon S3. Los objetos se componen de datos y metadatos. La parte de datos es opaca para Amazon S3 y los metadatos son conjuntos de pares nombre-valor que describen el objeto.
- **Buckets.** Un *bucket* es un contenedor para objetos almacenados en Amazon S3 y sirven para organizar estos objetos en estructuras más genéricas. Los *buckets* serían el equivalente a las bases de datos si se hace una analogía con una base de datos tradicional. Todos los objetos en AWS están almacenados en un *bucket*.
- **Regiones.** Como se ha comentado anteriormente, AWS tiene *data centers* por todo el mundo, S3 os permite elegir la región geográfica en la que vuestros datos serán almacenados físicamente. Los objetos almacenados en una región nunca la abandonan, a menos que se transfieran expresamente a otra región.

Bibliografía complementaria

Podéis encontrar más información de S3 en los siguientes vídeos. <<https://www.youtube.com/watch?v=77IMCiiMilo>>.

2.2. Ingesta (captura de datos)

Como habéis visto antes, la mayor parte de los servicios de AWS trabajan con datos existentes en S3, por lo tanto, antes de poder realizar cualquier procesado debéis llevar vuestros datos a S3 de alguna forma, al igual que en los entornos Hadoop podéis llevar datos a HDFS con Sqoop cuando el origen es una base

⁽²⁾https://docs.aws.amazon.com/es_es/AmazonS3/latest/userguide/RESTAPI.html

de datos relacional o directamente con el comando *put* si los datos residen en un directorio local de la máquina. S3 funciona exactamente igual, podéis *subir* los datos directamente a S3 por medio de su API (toda la documentación de la API se puede consultar en la documentación oficial de AWS)² con comando *put* o utilizar alguno de los servicios que tiene AWS para la ingesta de datos. Quizá el más utilizado es Kinesis:

Amazon Kinesis. Amazon Kinesis Data Streams (KDS) es un servicio de *streaming* de datos en tiempo real con un alto nivel de escalabilidad y durabilidad. KDS puede registrar de manera continua *gigabytes* de datos por segundo de cientos de miles de orígenes, como transmisiones de clics de sitios web, transmisiones de eventos de bases de datos, transacciones financieras, fuentes de redes sociales, registros de TI y eventos de seguimiento de ubicaciones. Los datos recopilados se encuentran disponibles en milisegundos para posibilitar los casos de uso de análisis en tiempo real, como cuadros de control en tiempo real, detección de anomalías y precios dinámicos, entre otros.

2.3. Procesamiento

Una vez tenéis los datos en S3 como en cualquier otra plataforma *big data* necesitáis herramientas para procesarlos. Las dos grandes herramientas de procesamiento que provee AWS son EMR (Elastic Map Reduce) y EC2 (Elastic Compute Cloud), que vais a ver a continuación. Ambas son las herramientas clave que AWS pone a disposición del usuario. En el caso de EC2, es un servicio de infraestructura (IaaS) que os permite levantar infraestructuras de forma sencilla y escalable en pocos minutos. EMR es una plataforma como servicio, se basa en una infraestructura base, pero permite configurar las herramientas de *big data* que el usuario decida (entre las disponibles), de forma que en unos pocos minutos podéis levantar un clúster completamente funcional.

- **Amazon EMR.**³ Amazon EMR es una plataforma de clúster administrado (PaaS) que simplifica la ejecución de los marcos de trabajo de *big data*, tales como Apache Hadoop o Apache Spark, en AWS para procesar y analizar grandes cantidades de datos. Mediante el uso de estos marcos de trabajo y proyectos de código abierto relacionados, como Apache Hive y Apache Pig, el usuario puede procesar datos para fines de análisis y cargas de trabajo de inteligencia empresarial. Además, es compatible con el uso de Amazon EMR para transformar y trasladar grandes cantidades de datos hacia otros almacenes de datos y bases de datos de AWS y desde otros almacenes de datos y bases de datos de AWS, tales como Amazon Simple Storage Service (Amazon S3) y Amazon DynamoDB.
- **Amazon EC2.**⁴ Amazon Elastic Compute Cloud (Amazon EC2) proporciona capacidad de computación escalable (IaaS) en la nube de Amazon Web Services (AWS). Amazon EC2 permite lanzar/levantar tantos servidores virtuales como el usuario necesite facilitando la configuración de la

Bibliografía complementaria

En el siguiente enlace encontraréis más información sobre Kinesis en el canal oficial de AWS. <https://www.youtube.com/watch?v=hLLgkTUmwOU&ab_channel=AmazonWebServices>.

Bibliografía complementaria

Para ampliar el conocimiento de EMR en el canal de AWS: <https://www.youtube.com/watch?v=ulQdA6MUnTk&ab_channel=AmazonWebServices>.

⁽³⁾https://docs.aws.amazon.com/es_es/emr/latest/ManagementGuide/emr-what-is-emr.html

⁽⁴⁾https://docs.aws.amazon.com/es_es/AWSEC2/latest/UserGuide/concepts.html

seguridad, las redes usadas y la administración del almacenamiento. Amazon EC2 permite escalar horizontal y verticalmente para controlar cambios en los requisitos o picos de uso, con lo que se reduce la necesidad de prever el tráfico. El uso de Amazon EC2 es prácticamente equivalente al uso de nube *on-premise* pero elimina la necesidad de invertir inicialmente en hardware, de manera que puede desarrollar e implementar aplicaciones en menos tiempo.

Bibliografía complementaria

Para ampliar el conocimiento de EC2 en el canal de AWS: <https://www.youtube.com/watch?v=TsRBftzZsQo&ab_channel=AmazonWebServices>.

2.4. Búsqueda y visualización


Hasta este punto, habéis visto como AWS ofrece herramientas de ingesta y de procesamiento en AWS de la información que reside en S3. Por último, veréis las herramientas que os permiten consultar y visualizar la información almacenada en S3. Como se ha comentado al principio, AWS dispone de muchos servicios, pero os centraréis en los tres más importantes: Glue, que actúa como *metastore* y como herramienta de ETL; Athena, que os permite realizar consultas SQL sobre los datos en S3; y QuickSight, que es una herramienta de visualización.

- **AWS Glue.**⁵ AWS Glue es un servicio plenamente administrado de ETL (extracción, transformación y carga) con el que resulta más rentable y sencillo categorizar los datos, limpiarlos, enriquecerlos y moverlos de manera fiable entre distintos *datastores*. AWS Glue consta de un repositorio de metadatos central conocido como AWS Glue Data Catalog, un motor de ETL que genera automáticamente código Python o Scala y una herramienta de planificación que se encarga de la monitorización de los trabajos y la aplicación de reintentos. AWS Glue no usa ningún tipo de servidor *backend*, por lo que no hay ninguna infraestructura que configurar ni administrar.

⁽⁵⁾https://docs.aws.amazon.com/es_es/glue/latest/dg/glue-dg.pdf#what-is-glue

En la figura 5 se muestra la interfaz de Glue para un *job* de ejemplo, podéis ver que es una aplicación muy intuitiva para hacer transformaciones ETL. Es una herramienta similar a las herramientas de BI PowerCenter o Talend.

Figura 5. Ejemplo de uso de la herramienta Glue de AWS



Fuente: AWS. <<https://aws.amazon.com/es/blogs/big-data/making-etl-easier-with-aws-glue-studio/>>.

- **Amazon Athena.**⁶ Amazon Athena es un servicio (SaaS) interactivo de consultas que facilita el análisis de datos directamente en Amazon Simple Storage Service (Amazon S3) utilizando el estándar SQL. Con unas pocas acciones en la consola de administración de AWS, se puede configurar Athena para usar datos almacenados en Amazon S3 y comenzar a ejecutar consultas *ad hoc*, obteniendo resultados en cuestión de segundos.

Igual que Glue, Athena no requiere un servidor, por lo que no hay que configurar ni administrar ninguna infraestructura, AWS solo facturará por el tiempo de ejecución de las consultas que ejecute. Athena escala automáticamente y ejecuta consultas en paralelo, por lo que los resultados se obtienen rápidamente, incluso con conjuntos de datos de gran tamaño y consultas complejas.

Athena es una herramienta muy útil y potente. Si se hace una analogía con los entornos *on-premise* que habéis visto el resto del curso, Athena es el equivalente AWS de Hive o Impala. En el caso de Hive e Impala, estas leen datos de HDFS y os permiten consultarlos utilizando el standard SQL, en el caso de Athena, esta lee los datos que tenéis almacenados en S3, pero la funcionalidad es la misma.


En la figura 6 podéis ver la interfaz web de Athena desde donde podéis consultar las tablas que creáis sobre los datos en S3, la interfaz es muy similar a la de HUE en los entornos Cludera. Cabe recordar que en AWS el funcionamiento de las tablas de Athena es el mismo que las tablas de Hive en Cludera, estas tablas son «vistas» sobre los ficheros que tenéis almacenados en S3, pero no son tablas con almacenamiento físico como en una base de datos tradicional. Athena es solo una herramienta que permite consultar los datos almacenados en S3 con lenguaje SQL.

Bibliografía complementaria

Para profundizar en el conocimiento de Glue es recomendable que veáis los vídeos del canal oficial de AWS en YouTube, en el que se explican todos los detalles del servicio: <https://www.youtube.com/watch?v=qgWMfNSN9f4&ab_channel=AmazonWebServices>.

⁽⁶⁾https://docs.aws.amazon.com/es_es/athena/latest/ug/athena-ug.pdf#what-is

Figura 6. Interfaz de Athena



Fuente: AWS. <<https://aws.amazon.com/es/blogs/aws/launch-amazon-athena-adds-support-for-querying-encrypted-data/>>.

- **Amazon QuickSight.**⁷ Es un servicio (SaaS) de inteligencia empresarial (BI) a escala en la nube para realizar visualizaciones y cuadros de control que permitan resumir la información de forma sencilla para cualquier usuario. Amazon QuickSight se conecta a datos almacenados a S3, pero puede combinar datos de muchas fuentes diferentes. Como servicio basado en la nube totalmente gestionado, Amazon QuickSight proporciona seguridad de nivel empresarial y disponibilidad global. QuickSight es una herramienta de visualización clásica, parecida a PowerBI o Tableau, aunque a día de hoy sigue siendo menos potente que estas y con menos funcionalidad. Sin embargo, cuenta con la ventaja de estar diseñada para leer y visualizar los datos almacenados en S3 de forma eficiente, lo que la hace una herramienta muy útil cuando se trabaja en AWS. Permite ajustar el número de usuarios simultáneos, desde tan solo 10 a 10.000 usuarios.


En la figura 7 se muestra la interfaz de usuario de QuickSight. Podéis ver que es una herramienta muy fácil de usar, el usuario solo tiene que definir el conjunto de datos con el que quiere trabajar y a continuación seleccionar el tipo de visualización que se usará y arrastrar los campos que se quieren mostrar. Soporta un buen número de tipos de diferentes de gráficas y métricas y permite enviar informes por correo electrónico con la periodicidad que se le indique tras refrescar el reporte automáticamente.

Bibliografía complementaria

En el siguiente enlace podéis encontrar información ampliada de Athena: <https://www.youtube.com/watch?v=L61cs9Qrp18&ab_channel=AmazonWebServices>.

⁽⁷⁾https://docs.aws.amazon.com/es_es/quicksight/latest/user/amazon-quicksight-user.pdf#welcome

Figura 7. Ejemplo de uso de la herramienta QuickSight



Fuente: AWS. <<https://aws.amazon.com/es/blogs/big-data/amazon-quicksight-now-allows-users-to-create-analyses-from-dashboards-and-import-custom-date-formats/>>.

Bibliografía complementaria

Para ampliar información sobre esta herramienta de visualización es recomendable que visitéis el siguiente enlace: <https://www.youtube.com/watch?v=VHAjFa5Tdmg&ab_channel=AmazonWebServices>.

Bibliografía complementaria

Si queréis ampliar la formación en AWS, podéis encontrar muchos más vídeos, ejercicios y prácticas en estas referencias: <<https://www.aws.training/>>, <<https://www.edx.org/school/aws>> y <<https://aws.qwiklabs.com>>.

3. Azure y Google Cloud

Este módulo se ha extendido en explicar algunas herramientas de AWS, ya que, además de ser hoy en día el *cloud* público más importante, es muy utilizado. En este último apartado veréis brevemente algunos servicios que ofrecen los otros dos grandes proveedores *cloud* públicos: Microsoft Azure y Google Cloud. Aunque obviamente todos tienen sus particularidades y diferencias, los grandes *clouds* públicos son en cierto punto muy similares entre sí:

- todos permiten crear infraestructura bajo petición y con las características que desee el usuario y
- todos tienen plataformas como servicio que permiten crear clústeres para computación con herramientas *big data* y software como servicios.


Un profesional habituado a trabajar en el entorno *cloud* de un proveedor concreto se puede adaptar a otros sin problema y en poco tiempo, igual que uno que esté habituado a trabajar en un entorno *on-premise* se adapta rápidamente a trabajar en *cloud*, aunque, obviamente, para ser un experto en cualquiera de las plataformas es necesario invertir tiempo en el análisis de las herramientas particulares.

3.1. Azure

El segundo *cloud* público en importancia y en cuota de mercado, puesto que representa un 20 % en 2020, es la plataforma de Microsoft: Azure. Anunciado en el Professional Developers Conference de Microsoft (PDC) en 2008 en su versión beta, pasó a ser un producto comercial el 1 de enero de 2010. Al igual que AWS, Azure dispone de gran cantidad de servicios en todas las modalidades: IaaS, PaaS y SaaS. En la figura 8 podéis encontrar una típica arquitectura en Azure que simularía todo lo que habéis visto en otros módulos mediante servicios *on-premise*. A continuación, se van a detallar los servicios más importantes.

Bibliografía complementaria

Para ampliar el conocimiento sobre Azure es recomendable que veáis este extenso vídeo que hace hincapié en todos los servicios más importantes del *cloud* de Microsoft <https://www.youtube.com/watch?v=tDuruX7XSac&ab_channel=edureka%21> o los cursos de <<https://docs.microsoft.com/es-es/learn/azure/>>.

Figura 8. Subconjunto del *stack* de servicios ofrecidos por Azure


Fuente: InfoQ. <<https://www.infoq.com/articles/azure-data-lake-analytics-usql/>>.

- **Almacenamiento.** La herramienta que proporciona Microsoft para el almacenamiento en la nube se llama **Azure Storage**, que ofrece:
 - un almacén de objetos escalable de forma masiva para objetos de datos,
 - un almacenamiento en disco para máquinas virtuales (VM) de Azure,
 - un servicio de sistema de archivos para la nube,
 - un almacén de mensajes para mensajería confiable y
 - un almacén NoSQL.
- **Ingesta.** Para la adquisición de datos en Azure la herramienta más utilizada es **Data Factory**. Es una herramienta muy potente que permite tanto la ingesta de datos desde orígenes muy diferentes como la transformación, ya que también actúa como herramienta visual de ETL, muy similar a Glue en AWS.
- **Procesamiento.** Para el procesamiento, Azure dispone de dos herramientas principales, por un lado, **HDInsight**, que permite crear clústeres con las herramientas más utilizadas del *big data* ya integradas, es muy similar a EMR en AWS; por otro lado, dispone de una plataforma muy potente de análisis de datos optimizada: **Databricks**.
- **Visualización.** En cuanto a la visualización, Azure ofrece **PowerBI**, una herramienta de visualización ya clásica de Microsoft, adaptándola para leer datos en la nube, pero que mantiene la interfaz y la funcionalidad del PowerBI de escritorio.

3.2. Google Cloud

Para finalizar veréis el último de los grandes *clouds* públicos actuales en cuota de mercado, aproximadamente el 9 % en 2020. Al igual que las dos plataformas vistas anteriormente, Google Cloud también tiene disponibles muchos servicios. En la figura 9 podéis encontrar una arquitectura básica utilizando servicios de Google Cloud. A continuación, se van a detallar los servicios más importantes.

Figura 9. Subconjunto del *stack* de servicios ofrecidos por Google Cloud



Fuente: Medium. <<https://medium.com/@sphe.malgas/cloud-architect-how-to-build-architectural-diagrams-of-google-cloud-platform-gcp-67ff7662f9ec>>.

Bibliografía complementaria

Si queréis ampliar la formación en Google Cloud se recomienda ver esta serie de vídeos <<https://www.youtube.com/playlist?list=PLEiEAq2VkUUI0xT8VNpjBuWvmnLHxPcsE>> o los cursos de <<https://cloud.google.com/training>>.

- **Almacenamiento.** La herramienta más conocida de almacenamiento en Google Cloud se llama **Cloud Storage**, que proporciona un almacenamiento central de datos escalable basado en *buckets* muy similar a S3 de AWS. Por otro lado, está **BigTable**, que es un servicio de base de datos NoSQL totalmente gestionado y escalable para grandes cargas de trabajo analíticas y operativas.
- **Ingesta.** Las dos herramientas principales de ingesta son **Pub/Sub** y **Dataflow** que permiten transferir y almacenar datos en tiempo real directamente en Cloud Storage.
- **Procesamiento.** Una vez tengáis los datos almacenados en Google Cloud, se puede utilizar DataFlow para cargar los datos en la gran herramienta del *cloud* de Google, que es BigQuery, una herramienta potentísima de procesamiento y análisis de datos basada en lenguaje SQL y enriquecida con muchas funcionalidades.

- **Visualización.** Google Cloud no se caracteriza por disponer de grandes herramientas de visualización; la herramienta más importante de la que dispone para este propósito es **Data Studio**, que permite hacer cuadros de mando a partir de los datos de BigQuery y Cloud Storage.

Bibliografía

Agut Navarro, Vicente (2017). *Desarrollo de aplicaciones en la nube (cloud computing)*. Trabajo fin de grado del grado en Ingeniería Informática. Escuela Técnica Superior d'Enginyeria Informàtica, Universidad Politècnica de Valencia. <<https://riunet.upv.es/bitstream/handle/10251/86557/AGUT%20-%20Desarrollo%20de%20aplicaciones%20en%20la%20nube%20%28Cloud%20Computing%29.pdf?sequence=1>>.

Amazon Web Services (2018, diciembre). *Big Data Analytics Options on AWS. AWS Whitepaper*. <<https://docs.aws.amazon.com/whitepapers/latest/big-data-analytics-options/big-data-analytics-options.pdf#welcome>>.

Amazon Web Services (2020, mayo). *Analytics Lens: AWS Well-Architected Framework*. <<https://docs.aws.amazon.com/wellarchitected/latest/analytics-lens/wellarchitected-analytics-lens.pdf#document-revisions>>.

Amazon Web Services (2021). «AWS. Free online courses from Amazon Web Services». *Edx* [sitio web]. <<https://www.edx.org/school/aws>>.

Amazon Web Services (s. f.). *AWS Training and Certification* [sitio web]. <<https://www.aws.training/>>.

Amazon Web Services (s. f.). *Become an Amazon Web Services expert with hands-on-training* [sitio web]. <<https://aws.wikilabs.com/>>.

Google (s. f.). «Google Cloud training». *Google Cloud* [sitio web]. <<https://cloud.google.com/training>>.

Guru 99 (s. f.). «Cloud Computing Tutorial for Beginners: What is & Architecture». *Guru99* [sitio web]. <<https://www.guru99.com/cloud-computing-for-beginners.html>>.

Instituto Nacional de Tecnología de la Comunicación (2011, marzo). *Riesgos y amenazas en cloud computing*. (S. l.): INTECO. <https://www.incibe.es/extfrontinteco/img/File/intecocert/EstudiosInformes/cert_inf_riesgos_y_amenazas_en_cloud_computing.pdf>.

Mell, Peter; Grance, Timothy (2011). *The NIST Definition of Cloud Computing* (special publication 800-145). Gaithersburg, MD: National Institute of Standards and Technology. <<http://dx.doi.org/10.6028/NIST.SP.800-145>>.

Microsoft (2021). «Microsoft Azure». *Microsoft* [sitio web]. <<https://docs.microsoft.com/es-es/learn/azure/>>.

Suppi Boldrito, Remo (2017). *Fundamentos y plataformas de cloud computing*. Barcelona: Oberta UOC Publishing, SL.

